

# Cadenas de Markov. Explicadas desde la genética

Ernesto Aceituno Romero, Román Aranguren España  
Miguel Crespo Orti y Andrés Fernández Cervell

Abril 2026

## 1. Introducción y justificación del uso de Cadenas de Markov en genética

A lo largo de la memoria se hará referencia a una hoja de cálculo y una simulación diseñadas para ejemplificar los casos de uso propuestos. Se puede acceder a ellas en [\[1\]](#) y [\[2\]](#).

Para la explicación del modelo, previamente introducimos algunos conceptos básicos de genética, útiles para la construcción del modelo y posterior estudio en este campo.

En la transmisión de genes, existen algunas características cuya transmisión es autosómica, es decir, no depende del sexo del individuo, y recesiva. Esto significa que existen genes dominantes y recesivos, donde la presencia de un gen dominante impide que el individuo manifieste la característica recesiva.

Un ejemplo de este tipo de transmisión es, por ejemplo, la característica de “manifestar albinismo” (producción reducida o ausente de melanina).

Por ello, un individuo puede tener uno de los siguientes genotipos (de manera simplificada), de los que transmite únicamente un gen.

| Genotipo | Manifiesta y/o transmite la característica (si es recesiva)         |
|----------|---------------------------------------------------------------------|
| AA       | Dominante. No manifiesta la característica ni puede transmitirla.   |
| Aa       | Híbrido. No manifiesta la característica aunque puede transmitirla. |
| aa       | Recesivo. Manifiesta la característica y la transmite.              |

A través de las leyes de Mendel y su trabajo con el estudio de guisantes, conocemos cómo es posible la transmisión de esta característica autosómica y recesiva. Por ejemplo, en el caso de dos individuos con genotipo híbrido ( $Aa - Aa$ ), las distintas combinaciones del gen transmisor establecen que, con probabilidad 0,25, su descendiente tendrá genotipo dominante; 0,5 genotipo híbrido; y 0,25 genotipo recesivo, por lo que individuos que no manifiestan una característica pueden tener descendencia que sí la manifieste.

$$Aa - Aa$$

$$AA \quad Aa \quad Aa \quad aa$$

En resumen, esta es la probabilidad para todos los posibles genotipos de los progenitores de que su descendencia tenga un genotipo determinado.

| Prog1. Prog2 | AA            | Aa            | aa            |
|--------------|---------------|---------------|---------------|
| AA - AA      | 1             | 0             | 0             |
| AA - Aa      | $\frac{1}{2}$ | $\frac{1}{2}$ | 0             |
| AA - aa      | 0             | 1             | 0             |
| Aa - Aa      | $\frac{1}{4}$ | $\frac{1}{2}$ | $\frac{1}{4}$ |
| Aa - aa      | 0             | $\frac{1}{2}$ | $\frac{1}{2}$ |
| aa - aa      | 0             | 0             | 1             |

Cuadro 1: Probabilidades de transmisión genética [5]

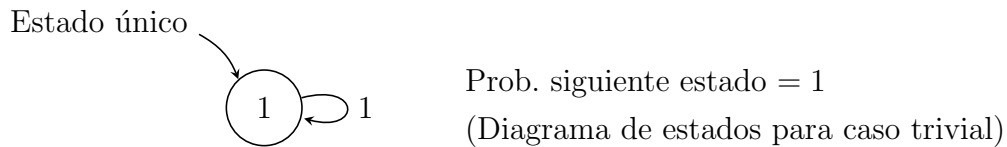
Observamos que en este proceso de transmisión de genes se cumple que el estado genético de la siguiente generación depende únicamente de la generación actual.

## 1.1. Modelo de Cadenas de Markov

Este modelo describe un sistema que cambia de un estado inicial a otro de un conjunto de estados mutuamente excluyentes, bien definidos y determinados, que cumplen que el cambio de un estado a otro no depende de cambios o estados anteriores, sino simplemente del estado actual.

A diferencia de otros modelos, en este se considera que el número de individuos de la población es constante (la población no aumenta ni disminuye) y lo que varía es el número de individuos que se encuentra en un estado y pasa a otro.


El caso trivial se aplica en un sistema con sólo un estado pues no se producen cambios y su estudio carece de interés.



En el caso de un sistema con dos estados ( $n = 2$ ) con probabilidades de que, partiendo del estado 1, se pase al 2  $p_{12}$ , y probabilidad de, partiendo del estado 2 pasar al 1  $p_{21}$ , el esquema sería de la siguiente forma.

$$0 \leq p_{12} \leq 1$$

$$0 \leq p_{21} \leq 1$$



Es claro que, como los estados son excluyentes y son únicos, la probabilidad de partiendo de un estado  $j$  cambiar al mismo estado  $j$  es:

$$1 - \sum_{\substack{i=1 \\ i \neq j}}^n p_{ji} = p_{jj}$$

Así podemos determinar una matriz cuadrada  $n \times n$  ( $n$ : número de estados del sistema) donde cada término  $p_{ij}$  indica la probabilidad de, partiendo del estado  $i$  pasar al estado  $j$ .

Para  $n = 2$ :

$$P = \begin{pmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{pmatrix} = \begin{pmatrix} 1 - p_{12} & p_{12} \\ p_{21} & 1 - p_{21} \end{pmatrix}$$

Si pasamos a  $n$  estados la matriz quedaría de la siguiente forma:

$$P = \begin{pmatrix} 1 - \sum_{i \neq 1}^n p_{1i} & p_{12} & p_{13} & \cdots & p_{1n} \\ p_{21} & 1 - \sum_{i \neq 2}^n p_{2i} & p_{23} & \cdots & p_{2n} \\ p_{31} & p_{32} & 1 - \sum_{i \neq 3}^n p_{3i} & \cdots & p_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & p_{n3} & \cdots & 1 - \sum_{i \neq n}^n p_{ni} \end{pmatrix}$$

Estas matrices se llaman matrices de transición. Se dicen estocásticas porque todos sus términos se interpretan como probabilidades. Sus elementos son no negativos y menores que uno, y su suma por fila es 1, pues la probabilidad de que se cambie de un estado a otro cualquiera de los posibles es 1.

Así, partiendo de una situación inicial en la que una población se distribuye entre los distintos estados (siempre que sean excluyentes) donde  $v_i$  determina el número de individuos en el estado " $i$ " podemos conocer cómo evoluciona en distintos periodos de tiempo.

$$v_0 = \begin{pmatrix} v_1^0 & v_2^0 & \cdots & v_n^0 \end{pmatrix}$$

$$v_{n+1} = v_n P$$

Luego en el periodo  $n$ , la población se encuentra en la situación:

$$v_n = v_0 P^n$$

Esto implica que la situación de estados cuando  $n \rightarrow \infty$  depende de las

propiedades de la matriz de transición.

Observamos la similitud entre la estructura del modelo y el de Malthus:

$$x_n = r^n x_0$$

**Nota:** Durante toda la memoria trabajaremos con matrices cuyas **filas** suman 1, y con vectores fila (1 x n). Equivalentemente, podríamos definir modelo como:

$$v_{n+1} = P v_n$$

Donde P es una matriz cuyas columnas suman 1, y los vectores  $v_{n+1}$  y  $v_n$  son vectores columna (n x 1).

## 1.2. Aplicando a transmisión de genes:

Extendiendo el modelo a esta simple interpretación de la transmisión de genes autosómicos y recesivos, si en una población todos sus individuos se cruzan con individuos con genotipo híbrido (Aa) y definimos como estado 1 genotipo dominante (AA), estado 2 genotipo híbrido y estado 3 genotipo recesivo (aa), con las probabilidades calculadas en Tabla 1, la matriz de transición quedaría de la siguiente forma.

$$P = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}$$

Estudiando el modelo concluiremos cómo evoluciona la característica en la población con el paso del tiempo para este ejemplo específico.

Usando la hoja de cálculo vemos cómo se alcanza un claro equilibrio cuando sobrepasamos la iteración 32:

|    | AA           | Aa   | aa           |
|----|--------------|------|--------------|
| 0  | 0,6          | 0,25 | 0,15         |
| 1  | 0,3625       | 0,5  | 0,1375       |
| 2  | 0,30625      | 0,5  | 0,19375      |
| 3  | 0,278125     | 0,5  | 0,221875     |
| 4  | 0,2640625    | 0,5  | 0,2359375    |
| 5  | 0,25703125   | 0,5  | 0,24296875   |
| 6  | 0,253515625  | 0,5  | 0,246484375  |
| 7  | 0,2517578125 | 0,5  | 0,2482421875 |
| 8  | 0,2508789063 | 0,5  | 0,2491210938 |
| 9  | 0,2504394531 | 0,5  | 0,2495605469 |
| 10 | 0,2502197266 | 0,5  | 0,2497802734 |
| 11 | 0,2501098633 | 0,5  | 0,2498901367 |
| 12 | 0,2500549316 | 0,5  | 0,2499450684 |
| 13 | 0,2500274658 | 0,5  | 0,2499725342 |
| 14 | 0,2500137329 | 0,5  | 0,2499862671 |
| 15 | 0,2500068665 | 0,5  | 0,2499931335 |
| 16 | 0,2500034332 | 0,5  | 0,2499965668 |
| 17 | 0,2500017166 | 0,5  | 0,2499982834 |
| 18 | 0,2500008583 | 0,5  | 0,2499991417 |
| 19 | 0,2500004292 | 0,5  | 0,2499995708 |
| 20 | 0,2500002146 | 0,5  | 0,2499997854 |
| 21 | 0,2500001073 | 0,5  | 0,2499998927 |
| 22 | 0,2500000536 | 0,5  | 0,2499999464 |
| 23 | 0,2500000268 | 0,5  | 0,2499999732 |
| 24 | 0,2500000134 | 0,5  | 0,2499999866 |
| 25 | 0,2500000067 | 0,5  | 0,2499999933 |
| 26 | 0,2500000034 | 0,5  | 0,2499999966 |
| 27 | 0,2500000017 | 0,5  | 0,2499999983 |
| 28 | 0,2500000008 | 0,5  | 0,2499999992 |
| 29 | 0,2500000004 | 0,5  | 0,2499999996 |
| 30 | 0,2500000002 | 0,5  | 0,2499999998 |
| 31 | 0,2500000001 | 0,5  | 0,2499999999 |
| 32 | 0,2500000001 | 0,5  | 0,2499999999 |
| 33 | 0,25         | 0,5  | 0,25         |
| 34 | 0,25         | 0,5  | 0,25         |
| 35 | 0,25         | 0,5  | 0,25         |

Figura 1: Hoja de cálculo Transmisión de genes

Gráficamente podemos apreciar la tendencia del modelo:




Figura 2: Gráfica Transmisión de genes

**Nota:** durante toda la memoria, las gráficas aportadas serán representadas de forma continua; a pesar de tratarse de un modelo discreto, pues consideramos que aporta una mayor claridad visual.

### 1.3. Algoritmo y simulación:

Consideramos interesante el desarrollo de un sencillo programa que nos permita probar el modelo con diferentes casos de uso. Se propone la siguiente implementación, que puede ser descargada en [\[3\]](#).

Comenzamos definiendo dos funciones auxiliares. La primera se usa para multiplicar un vector por una matriz, y la segunda nos ayudará a identificar cuándo el modelo habrá convergido. En nuestro algoritmo esto ocurre cuando la diferencia máxima entre los vectores resultantes de dos iteraciones (el mayor valor absoluto de la resta componente a componente) sea menor que  $10^{-10}$ . Además, tomamos 40 como el máximo de iteraciones, suficiente para los datos que vamos a manejar. En caso de necesitar mayor precisión o trabajar con vectores de mayor dimensión, es conveniente aumentar esta constante.

```

1  #include <iostream>
2  #include <vector>
3  #include <cmath>
4
5  using namespace std;
6
7  const double TOL = 1e-10; //Tolerancia para la convergencia
8  const int MAX_ITER = 40; //Número máximo de iteraciones
9
10 //Función que multiplica el vector de estado por la matriz de transición
11 vector<double> multiply(const vector<double>& state, const vector<vector<double>>& transition) {
12     vector<double> newState(state.size(), 0.0);
13     for (int i = 0; i < state.size(); ++i) {
14         for (int j = 0; j < transition[i].size(); ++j) {
15             newState[j] += state[i] * transition[i][j];
16         }
17     }
18     return newState;
19 }
20
21 //Función que calcula diferencia máxima entre dos vectores
22 //Definimos la diferencia máxima como la mayor diferencia absoluta entre los elementos correspondientes de dos vectores
23 double maxDifference(const vector<double>& a, const vector<double>& b) {
24     double maxDiff = 0.0;
25     for (int i = 0; i < a.size(); ++i) {
26         double diff = fabs(a[i] - b[i]);
27         if (diff > maxDiff) {
28             maxDiff = diff;
29         }
30     }
31     return maxDiff;
32 }

```

Figura 3: Algoritmo: Primera parte

La siguiente función es el núcleo del algoritmo. Apoyándose en las dos anteriores, multiplica el vector de la iteración anterior por la matriz fija, comprobando si se ha llegado a la convergencia.

```

33
34 //Función que calcula la distribución estacionaria
35 vector<double> markov_chains(const vector<vector<double>>& transition, const vector<double>& initialState, int &iter, bool &convergencia) {
36     vector<double> state = initialState;
37     convergencia = false;
38     for (iter = 1; iter <= MAX_ITER && maxDifference(state, multiply(state, transition)) >= TOL; ++iter) {
39         vector<double> newState = multiply(state, transition);
40         state = newState;
41     }
42     if (iter < MAX_ITER) {
43         convergencia = true;
44     }
45     return state;
46 }

```

Figura 4: Algoritmo: Segunda parte

Finalmente, lo aplicamos a nuestro caso de uso e imprimimos por pantalla el resultado.

```

49 int main() {
50     //Ejemplo de uso
51     vector<vector<double>> transition = {
52         {0.5, 0.5, 0.0},
53         {0.25, 0.5, 0.25},
54         {0, 0.5, 0.5}
55     };
56     vector<double> initialState = {0.6, 0.25, 0.15}; //Estado inicial
57
58     int iterations = 0;
59     bool convergencia = false;
60     vector<double> stationaryDistribution = markov_chains(transition, initialState, iterations, convergencia);
61
62     cout << "Distribución estacionaria: ";
63     for (double prob : stationaryDistribution) {
64         cout << prob << " ";
65     }
66     cout << endl;
67     cout << "Número de iteraciones: " << iterations << endl;
68     cout << "Convergencia alcanzada: " << (convergencia ? "Sí" : "No") << ". Tolerancia " << TOL << endl;
69
70     return 0;
71 }

```

Figura 5: Algoritmo: Tercera parte

Vemos que el resultado es el esperado:



```

Distribución estacionaria: 0.25 0.5 0.25
Número de iteraciones: 32
Convergencia alcanzada: Sí. Tolerancia 1e-10

```

Figura 6: Algoritmo: Cuarta parte

Para hacer más visual nuestro programa, decidimos apoyarnos en la herramienta de inteligencia artificial Claude, para diseñar, a partir del código anterior, una simulación [2] en HTML que nos permitiese ver la evolución del modelo a lo largo de las iteraciones. Podemos ver el resultado al probarlo en nuestro caso de uso:



Figura 7: Simulación: Transmisión de genes

## 2. Demostración de que 1 es valor propio del sistema

Previo a esta demostración, recordemos la definición de valor propio. En álgebra lineal, dada una matriz cuadrada  $A$  de tamaño  $n \times n$  ( $A \in M_{n \times n}(\mathbb{K})$ ), decimos que un escalar  $\lambda \in \mathbb{K}$  es valor propio de  $A$  si existe un vector fila no

nulo  $v$  que cumple:

$$vA = \lambda v$$

Luego, si queremos demostrar que 1 es valor propio, basta con encontrar  $v \neq 0$  que cumpla  $vA = v$ .

Cabe recordar, pues será útil para nuestra demostración, que las matrices con las que trabajamos en este modelo son matrices estocásticas pues cumplen:

- (i) Todos sus términos son no negativos

$$a_{ij} \geq 0 \quad \forall i = 1, \dots, n \quad , \quad \forall j = 1, \dots, n$$

- (ii) La suma de sus términos por filas es 1 para todas sus filas

$$\sum_{j=1}^n a_{ij} = 1 \quad \forall i = 1, \dots, n$$

### **Demostración:**

Nota: recordemos que los autovalores por la derecha y por la izquierda de una matriz son exactamente los mismos. Podemos entonces buscar un  $\lambda_0$  tal que

$$Av = \lambda_0 v$$

con  $\lambda_0 = \lambda$

Sea  $A \in M_{n \times n}(\mathbb{R})$  estocástica, tomamos  $v \in \mathbb{R}^n$  el vector columna  $\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$ ,

veamos que se cumple que  $Av = v$ .

$$Av = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} a_{11} \cdot 1 + a_{12} \cdot 1 + \cdots + a_{1n} \cdot 1 \\ a_{21} \cdot 1 + a_{22} \cdot 1 + \cdots + a_{2n} \cdot 1 \\ \vdots \\ a_{n1} \cdot 1 + a_{n2} \cdot 1 + \cdots + a_{nn} \cdot 1 \end{pmatrix}$$

$$= \begin{pmatrix} \sum_{j=1}^n a_{1j} \\ \sum_{j=1}^n a_{2j} \\ \vdots \\ \sum_{j=1}^n a_{nj} \end{pmatrix} \stackrel{(ii)}{=} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = v = 1 \cdot v$$

Luego queda demostrado que 1 es valor propio de  $A$ .

## 2.1. Interpretación de este resultado:

El principal significado de este resultado es que  $\exists v_i$  (vector que representa la situación de estados en el periodo  $i$ ) que cumple que  $v_i = v_i P$  sea cual sea la matriz de transición, es decir, este vector es estacionario y para todo modelo de cadenas de Markov existe una situación de estados “estable” que se mantiene constante en el tiempo.

## 2.2. Acotación de las soluciones

Para reafirmar la existencia de la mencionado situación de estados “estable”, es interesante comprobar que las soluciones del modelo están siempre acotadas. Además, podemos pensar que, dada la propiedad estocástica de la matriz de transición, es lógico que las componentes de cualquier vector solución sumen 1. Veámoslo:

### Demostración:

Supongamos que el vector inicial  $X_0$  es un vector de probabilidad válido, lo que significa que sus componentes cumplen:

$$x_i^{(0)} \geq 0 \quad \forall i, \quad \text{y} \quad \sum_{i=1}^k x_i^{(0)} = 1$$

Queremos demostrar por inducción que para cualquier paso  $n$ , la suma de las componentes del vector  $X_{n+1}$  sigue siendo exactamente 1.

El caso base se cumple trivialmente por ser el vector inicial válido.

**1. Aplicación del producto de matrices:** Por definición del producto de un vector fila por una matriz, cada componente  $j$  del nuevo vector

$X_{n+1} = X_n M$  se calcula como:

$$x_j^{(n+1)} = \sum_{i=1}^k x_i^{(n)} m_{ij}$$

**2. Suma de todas las componentes del nuevo vector:** Si sumamos todas las componentes del vector  $X_{n+1}$  (sumando sobre el índice  $j$ ):

$$\sum_{j=1}^k x_j^{(n+1)} = \sum_{j=1}^k \left( \sum_{i=1}^k x_i^{(n)} m_{ij} \right)$$

**3. Intercambio en el orden de sumación:** (sumamos primero respecto a  $j$  y luego respecto a  $i$ ). El término  $x_i^{(n)}$  sale del sumatorio interno:

$$\sum_{j=1}^k x_j^{(n+1)} = \sum_{i=1}^k x_i^{(n)} \left( \sum_{j=1}^k m_{ij} \right)$$

**4. Uso de la propiedad estocástica de la matriz:** Por ser  $M$  estocástica por filas, la suma de los elementos de cada una de sus filas es exactamente 1 (es decir,  $\sum_{j=1}^k m_{ij} = 1$  para cada  $i$ ). Sustituyendo este valor:

$$\sum_{j=1}^k x_j^{(n+1)} = \sum_{i=1}^k x_i^{(n)} \cdot (1) = \sum_{i=1}^k x_i^{(n)}$$

Como el vector anterior sumaba 1, el nuevo vector también suma 1.

Por hipótesis de inducción, sabemos que la suma de las componentes en el paso anterior era 1 ( $\sum_{j=1}^k x_j^{(n)} = 1$ ). Por lo tanto:

$$\sum_{i=1}^k x_i^{(n+1)} = 1$$

Así, las soluciones, además de estar acotadas, suman siempre 1.

Aplicando el Teorema 4.1.2 de [9], sabemos que, por estar las soluciones del sistema acotadas, tenemos:

1.  $\rho(M) \leq 1$ .
2. La dimensión de  $\ker(M - \lambda I)$  es igual a la multiplicidad algebraica de  $\lambda$  si  $\lambda \in \sigma(M)$  y  $|\lambda| = 1$ .

Por tanto, no pueden existir valores propios del sistema mayores que 1.

### 3. ¿Es 1 un valor propio dominante?

Hasta ahora hemos demostrado que 1 es valor propio y que  $\rho(M) \leq 1$ . Sin embargo, para que una cadena de Markov converja a una distribución estacionaria única a largo plazo, necesitamos descartar la existencia de otros valores propios complejos o negativos con módulo 1 (por ejemplo,  $\lambda = -1$ , que causaría oscilaciones periódicas).

Para garantizar la **dominancia estricta** del valor propio 1, la matriz debe cumplir una condición fundamental basada en el Teorema de Perron-Frobenius:

**Positividad estricta (o Regularidad):** Existe un número entero  $m \geq 1$  tal que la matriz  $P^m$  es estrictamente positiva (todas sus entradas son mayores que cero). En términos biológicos, esto significa que es posible transitar desde cualquier estado a cualquier otro estado en  $m$  pasos.

Si se cumple esta condición de regularidad, el Teorema de Perron-Frobenius nos proporciona las siguientes garantías:

- El radio espectral  $\rho(P) = 1$  es un valor propio simple (no repetido).
- Es estrictamente dominante:  $|\lambda_k| < 1$  para todo  $\lambda_k \neq 1$ .
- Existe un único vector propio asociado (la distribución estacionaria  $\pi$ ) cuyas componentes son todas estrictamente positivas y suman 1.

En conclusión, una matriz de transición  $P$  que cumpla la condición de regularidad tendrá siempre a 1 como su valor propio dominante.

#### 3.1. Interpretación del resultado

Sabemos entonces, por la Nota 4.1.1 de [9], que:

$$\lim_{n \rightarrow \infty} X_n = \alpha \cdot 1 \cdot v_1 = \alpha v_1$$

Donde:

- $v_1$  es el autovector asociado al autovalor  $\lambda_1 = 1$  (es decir, el generador del subespacio propio  $Ker(M - I)$ ).
- $\alpha$  es una constante escalar.

Esto nos dice que, si la matriz de transición cumple las propiedades necesarias para que 1 sea valor propio dominante, la dirección de sus soluciones viene únicamente determinada por el vector propio asociado, independientemente del valor inicial de nuestro problema. Esto implica que, cambiando  $X_0$ , llegaremos siempre al mismo resultado.

Para comprobar estas propiedades, retomamos el ejemplo de la tabla 1. Consideramos la matriz de transición:

$$P = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}$$

Vemos fácilmente que P verifica la condición de Regularidad del Teorema de Perron-Frobenius, pues

$$P^2 = \begin{pmatrix} 0,375 & 0,5 & 0,125 \\ 0,25 & 0,5 & 0,25 \\ 0,125 & 0,5 & 0,375 \end{pmatrix}$$

Por lo tanto, tenemos garantizado que 1 es su valor propio dominante.

Buscamos ahora el vector fila  $v = (x, y, z)$  (autovector por la izquierda) asociado a este valor propio dominante para hallar el estado estacionario del sistema. Esto se formaliza resolviendo el sistema homogéneo  $v(P - I) = 0$ :

$$\begin{pmatrix} x & y & z \end{pmatrix} \begin{pmatrix} \frac{1}{2} - 1 & \frac{1}{2} & 0 \\ \frac{1}{4} & \frac{1}{2} - 1 & \frac{1}{4} \\ 0 & \frac{1}{2} & \frac{1}{2} - 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \end{pmatrix}$$

Operando:

$$\begin{pmatrix} x & y & z \end{pmatrix} \begin{pmatrix} -1/2 & 1/2 & 0 \\ 1/4 & -1/2 & 1/4 \\ 0 & 1/2 & -1/2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \end{pmatrix}$$

Multiplicando el vector fila por cada una de las columnas de la matriz de coeficientes, obtenemos el siguiente sistema de ecuaciones explícitas:

1.  $-\frac{1}{2}x + \frac{1}{4}y = 0 \implies y = 2x$
2.  $\frac{1}{2}x - \frac{1}{2}y + \frac{1}{2}z = 0$
3.  $\frac{1}{4}y - \frac{1}{2}z = 0 \implies y = 2z$

Igualando las expresiones para  $y$  de la primera y tercera ecuación, deducimos de inmediato que  $2x = 2z \implies x = z$ .

Por lo tanto, el subespacio propio izquierdo asociado al valor propio dominante  $\lambda = 1$  viene dado por:

$$E_I(1) = \{v \in \mathbb{R}^3 \mid v = \alpha(1, 2, 1), \alpha \in \mathbb{R}\}$$

Normalizando el vector, obtenemos el estado estacionario que habíamos observado empíricamente:

$$v_{estacionario} = (0, 25 \quad 0, 5 \quad 0, 25)$$

## 4. Aplicación a la genética

### 4.1. Introducción Biológica

El ADN es, en esencia, el manual de instrucciones de todos los seres vivos, ya que contiene la información necesaria para construir y mantener nuestro organismo. Su estructura es una doble hélice formada por nucleótidos, entre cuyas partes destacan las bases nitrogenadas. Distinguimos cuatro principales: Adenina (A), Timina (T), Citosina (C) y Guanina (G).

Antes de entrar en más detalle, debemos mencionar dos de los hitos científicos más relevantes en el campo de la genética. Por un lado, la "Foto-

grafía 51". Mediante técnicas de difracción de rayos X, la química británica Rosalind Franklin (Figura 8) probó empíricamente en 1952 la verdadera estructura del ADN: la doble hélice. Cabe destacar que, pese a la enorme relevancia de su investigación, ella quedó relegada a un segundo plano cuando otros científicos coetáneos utilizaron su aportación sin permiso para publicar sus propios modelos. Por otro lado, el bioquímico, también británico, Frederick Sanger (Figura 9) desarrolló una técnica pionera para leer el orden exacto de los nucleótidos en una cadena, un logro que le valió su segundo Premio Nobel. Esto dio pie a la secuenciación genética, con avances tan significativos como el Proyecto Genoma Humano (1990-2003), y a su posterior análisis, que abordamos con el modelo de las cadenas de Markov en este trabajo. [15]




Figura 8: Rosalind Franklin




Figura 9: Frederick Sanger




Figura 10: Doble hélice de ADN

Una cadena de la hélice es complementaria de la otra. Las bases se co-



nectan transversalmente siguiendo una regla estricta: la A siempre se empareja con la T, y la C con la G (Figura 10). Este emparejamiento es vital para que la célula pueda hacer copias exactas de su ADN durante la división celular. Estas cuatro letras conforman el abecedario de la vida; modificando su orden a lo largo de la cadena, se puede codificar cualquier gen. Cabe destacar que cuando hablamos de secuenciar el ADN, se refiere al de una de las hélices, no apareciendo la copia que acabamos de mencionar. El cuerpo interpreta este "código genético" leyendo las letras en grupos de tres, llamados codones. Cada codón se corresponde con un aminoácido específico, y la unión secuencial de muchos aminoácidos forma las proteínas, que son las moléculas encargadas de realizar el trabajo funcional y estructural en el organismo.

Gracias a la precisión de este código, podemos comparar secuencias de ADN para comprobar si pertenecen a la misma persona, determinar parentescos o identificar especies. Ahora bien, solo alrededor del 2 % de nuestro ADN contiene las instrucciones reales (los genes) para fabricar proteínas. El 98 % restante se conoce como ADN "no codificante". Pero lejos de ser inútil, este ADN contiene secuencias muy variables (se utilizan en ciencias forenses para la identificación humana) que alberga promotores y potenciadores genéticos que controlan cómo y cuándo se expresa ese 2 % codificante.

En el genoma de los mamíferos, cuando aparece el dinucleótido CG (guanina justo después de citosina, también conocido como CpG), la citosina suele sufrir un proceso químico llamado metilación. Evolutivamente, esta citosina metilada es inestable y tiende a sufrir una desaminación espontánea que la convierte en timina (mutación de C a T). Por este motivo, la frecuencia del par CG en el genoma es mucho menor de lo esperado. Sin embargo, existen unas regiones cortas de ADN "protegidas" contra esta metilación, donde la concentración de pares C-G se mantiene inusualmente alta: las llamadas **islas CpG**.

Estas zonas son de vital importancia porque se ubican justo en la región promotora (la "puerta de entrada") de aproximadamente el 70 % de los genes, en particular de los llamados "genes esenciales" o constitutivos (*housekeeping genes*) [7].

Además, las islas CpG actúan como el "interruptor" principal de dichos genes. Mediante la metilación reversible de estas islas, la célula puede bloquear la transcripción del gen, silenciando (apagando) el gen por completo sin alterar




Figura 11: Isla CpG

la secuencia original de letras del ADN. Esta capacidad de encender y apagar genes forma parte de la epigenética, un mecanismo fundamental para la diferenciación celular y la adaptación al entorno. Su lectura clínica permite a los médicos diagnosticar enfermedades de forma temprana, detectando, por ejemplo, si un tumor ha bloqueado de forma anómala un gen supresor de tumores que debería estar protegiéndonos [6] (Figura 11).

Así, por ejemplo, en el caso de los humanos, identificar una isla CpG (entre 300 y 3000 pares de bases) computacionalmente es muy interesante para los científicos, pues permite localizar fácilmente el inicio de un gen (cuya longitud media ronda los 30.000 pares de bases) y su estado, sin tener que rastrear a ciegas todo el genoma humano (compuesto por unos 3.200 millones de pares de bases). [8]

## 4.2. Aplicación del modelo de las cadenas de Markov

Para el estudio de la densidad de los nucleótidos en el código genético, resulta especialmente útil el empleo del modelo matemático de las **Cadenas de Markov**. Como se ha comentado en secciones previas, este modelo estocástico asume que la probabilidad de transición de una base a otra es un evento que depende únicamente del nucleótido inmediatamente anterior (ver apartado 1.1). Dada la importancia de los dinucleótidos en la definición de las islas CpG, el uso de este modelo es idóneo para estudiar la probabilidad de aparición de la Guanina (G) tras la Citosina (C).

En la aplicación del modelo, se construye una matriz de transición asociando un parámetro de probabilidad a cada posible cambio de estado. Matemáticamente, la probabilidad de que aparezca una secuencia  $X = x_1x_2 \dots x_L$  se calcula mediante la probabilidad condicionada de cada par adyacente:




Figura 12: Diagrama de transición entre nucleótidos

$$a_{st} = P(x_i = t \mid x_{i-1} = s). \quad (1)$$

$$\begin{aligned} P(X) &= P(x_L \mid x_{L-1})P(x_{L-1} \mid x_{L-2}) \cdots P(x_2 \mid x_1)P(x_1) \\ &= P(x_1) \prod_{i=2}^L a_{x_{i-1}x_i}. \end{aligned} \quad (2)$$

En el estudio de referencia [11], se aporta una tabla de transición obtenida a partir de mediciones empíricas de áreas del genoma que son islas CpG (+) y áreas que no lo son (−). Para obtener los valores de estas matrices, se cuenta el número de veces que un nucleótido  $x_i$  sigue a un nucleótido  $x_{i-1}$ , y se divide entre la suma total de apariciones de ese nucleótido  $x_{i-1}$  seguido de cualquier otra base. Es interesante destacar cómo los estudios llevados a cabo por Durbin concluyen que la probabilidad de que una Guanina aparezca inmediatamente después de una Citosina es 3.5 veces superior en las islas CPG que fuera de estas (0.274 vs 0.078).

| + | A     | C     | G     | T     | − | A     | C     | G     | T     |
|---|-------|-------|-------|-------|---|-------|-------|-------|-------|
| A | 0.180 | 0.274 | 0.426 | 0.120 | A | 0.300 | 0.205 | 0.285 | 0.210 |
| C | 0.171 | 0.368 | 0.274 | 0.188 | C | 0.322 | 0.298 | 0.078 | 0.302 |
| G | 0.161 | 0.339 | 0.375 | 0.125 | G | 0.248 | 0.246 | 0.298 | 0.208 |
| T | 0.079 | 0.355 | 0.384 | 0.182 | T | 0.177 | 0.239 | 0.292 | 0.292 |

Figura 13: Matrices de transición

Podemos emplear estas matrices para, mediante el modelo de las cadenas de Markov, hacer un estudio a nivel local o a largo plazo de las cadenas de ADN supuesto que pertenecemos o no a una isla CpG.

Para el caso local, definimos un vector interruptor con un 1 en la posición de la letra actual

$$u_i = \begin{pmatrix} 0 & 1 & 0 & 0 \end{pmatrix} \quad (3)$$

Con esto, podemos obtener la probabilidad de que cada una de las cuatro letras sea la siguiente (no es más que coger la fila correspondiente). En la práctica, es interesante, sobre una secuencia ya conocida, calcular la probabilidad de que a partir de cierto nucleótido, se den cada una de las transiciones según los modelos + y -, para ver en cuál de los dos es más probable que se encuentre dicha secuencia.

$$P(X) = P(x_1) \prod_{i=2}^L (v_{i-1}^T \cdot P \cdot v_i) \quad (4)$$

Sin embargo, para el estudio del comportamiento a largo plazo nos interesa una perspectiva más global, siendo el vector inicial la concentración de cada nucleótido en la secuencia, haciendo un estudio clásico conforme al modelo de las cadenas de Markov.

$$v_n = v_0 P^n$$

#### 4.2.1. Estudio de la distribución estacionaria de las islas CpG

Apoyándonos en estos datos, proponemos aplicar el modelo de Markov para estudiar cómo podríamos esperar que se distribuyesen los 4 nucleótidos en cadenas lo suficientemente extensas, diferenciando entre ambas regiones.

Comenzamos el estudio usando [1]. Tras trasladar los datos proporcionados por el estudio, analizamos los casos por separado:

## Caso 1: Islas CpG

*Observación:* Se ha ajustado la segunda fila de la tabla. En el libro citado, los datos suman 1,001, presumiblemente debido al redondeo de tres cifras, lo que provocaba que en iteraciones avanzadas la suma de las probabilidades fuese superior a 1. Para mantener la fidelidad al experimento, se ha optado por restar 0,0025 a cada celda de dicha fila.

Tomamos como valor inicial un vector que representa el porcentaje inicial de cada nucleótido en la muestra. El único requisito a imponer es que la suma de sus componentes sea igual a 1, pues veremos que la elección del vector inicial es totalmente indiferente para el resultado en el largo plazo.

Por ejemplo, tomando una cadena con un 25 % de nucleótidos de Citosina y un 75 % de Guanina, tenemos que a partir de la iteración 11 los datos convergen con una tolerancia de  $10^{-10}$  (Figura 14)

Además, es importante observar el desbalanceo que se produce entre las distintas bases nitrogenadas. Mientras la Adenina y la Timina comparten alrededor de 0.154 de probabilidad, la Citosina y la Guanina se disparan hasta un 0.34.

Estas diferencias son fácilmente apreciables gráficamente (Figura 15)

|    | A        | B            | C            | D            | E            |
|----|----------|--------------|--------------|--------------|--------------|
| 1  | Isla CPG | A            | C            | G            | T            |
| 2  | A        | 0,180        | 0,274        | 0,426        | 0,12         |
| 3  | C        | 0,17075      | 0,36775      | 0,27375      | 0,18775      |
| 4  | G        | 0,161        | 0,339        | 0,375        | 0,125        |
| 5  | T        | 0,079        | 0,355        | 0,384        | 0,182        |
| 6  |          |              |              |              |              |
| 7  |          | A            | C            | G            | T            |
| 8  | 0        | 0            | 0,25         | 0,75         | 0            |
| 9  | 1        | 0,1634375    | 0,3461875    | 0,3496875    | 0,1406875    |
| 10 | 2        | 0,1559442656 | 0,3405804531 | 0,3495500156 | 0,1539252656 |
| 11 | 3        | 0,1546617287 | 0,341118115  | 0,3498547141 | 0,1543654422 |
| 12 | 4        | 0,1546065082 | 0,3412239805 | 0,349738828  | 0,1544306833 |
| 13 | 5        | 0,1546011414 | 0,3412316573 | 0,34972588   | 0,1544413212 |
| 14 | 6        | 0,154600242  | 0,3412323971 | 0,3497249248 | 0,1544424361 |
| 15 | 7        | 0,1546001407 | 0,3412324947 | 0,3497248141 | 0,1544425506 |
| 16 | 8        | 0,1546001304 | 0,3412325059 | 0,3497248    | 0,1544425637 |
| 17 | 9        | 0,1546001292 | 0,3412325071 | 0,3497247985 | 0,1544425652 |
| 18 | 10       | 0,1546001291 | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 19 | 11       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 20 | 12       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 21 | 13       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 22 | 14       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 23 | 15       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 24 | 16       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 25 | 17       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 26 | 18       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 27 | 19       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |
| 28 | 20       | 0,154600129  | 0,3412325072 | 0,3497247983 | 0,1544425654 |

Figura 14: Hoja de cálculo Isla CpG




Figura 15: Gráfica Isla CpG

## Caso 2: Secuencias restantes

En este caso, debido a la disminución en la probabilidad de que tras una Citosina aparezca una Guanina, las probabilidades del modelo tras varias iteraciones se equilibran, e incluso vemos como estas dos bases nitrogenadas están ligeramente menos presentes.

Tomando el mismo vector inicial, tras unas 11 iteraciones, llegamos a una cadena en la que la probabilidad de que una base nitrogenada sea Adenina es alrededor de 0.262; Citosina, 0.246; Guanina 0.239 y Timina 0.253.(16)

| Secuencias restantes | A            | C            | G            | T            |
|----------------------|--------------|--------------|--------------|--------------|
| A                    | 0,3          | 0,205        | 0,285        | 0,21         |
| C                    | 0,322        | 0,298        | 0,078        | 0,302        |
| G                    | 0,248        | 0,246        | 0,298        | 0,208        |
| T                    | 0,177        | 0,239        | 0,292        | 0,292        |
|                      |              |              |              |              |
|                      | A            | C            | G            | T            |
| 0                    | 0            | 0,25         | 0            | 0,75         |
| 1                    | 0,21325      | 0,25375      | 0,2385       | 0,2945       |
| 2                    | 0,256957     | 0,24839025   | 0,23763575   | 0,257017     |
| 3                    | 0,2614944355 | 0,246581937  | 0,238471602  | 0,2534520255 |
| 4                    | 0,2618496802 | 0,2463268247 | 0,238831834  | 0,2529916611 |
| 5                    | 0,2618819605 | 0,2463022164 | 0,2388861028 | 0,2529297204 |
| 6                    | 0,2618862158 | 0,2463000468 | 0,2388914686 | 0,2529222688 |
| 7                    | 0,2618868056 | 0,2462998117 | 0,2388919353 | 0,2529214474 |
| 8                    | 0,2618868772 | 0,246299781  | 0,2388919843 | 0,2529213575 |
| 9                    | 0,261886885  | 0,2462997771 | 0,2388919906 | 0,2529213472 |
| 10                   | 0,2618868859 | 0,2462997767 | 0,2388919914 | 0,252921346  |
| 11                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 12                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 13                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 14                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 15                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 16                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 17                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 18                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 19                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |
| 20                   | 0,261886886  | 0,2462997766 | 0,2388919915 | 0,2529213458 |

Figura 16: Hoja de Cálculo Secuencias Restantes




Figura 17: Gráfica Secuencias Restantes

Podemos comparar estos resultados con los proporcionados por nuestra simulación. Cambiando los datos iniciales a un vector de 0.25 en todas sus componentes nos queda:

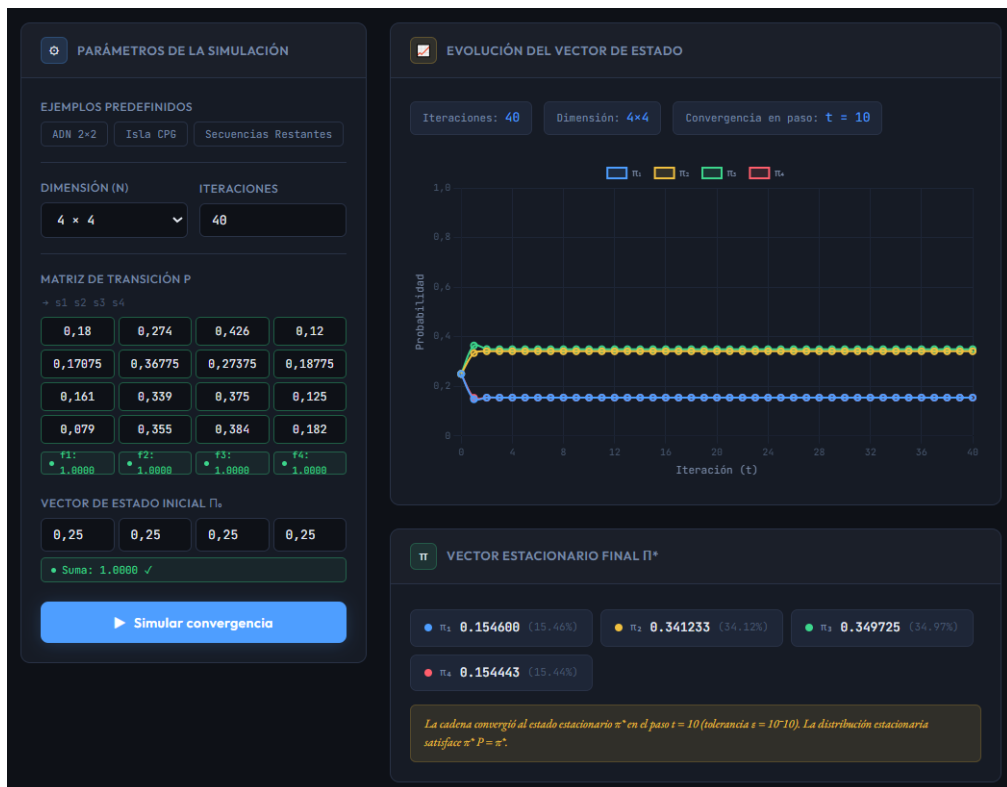


Figura 18: Animación Isla CPG



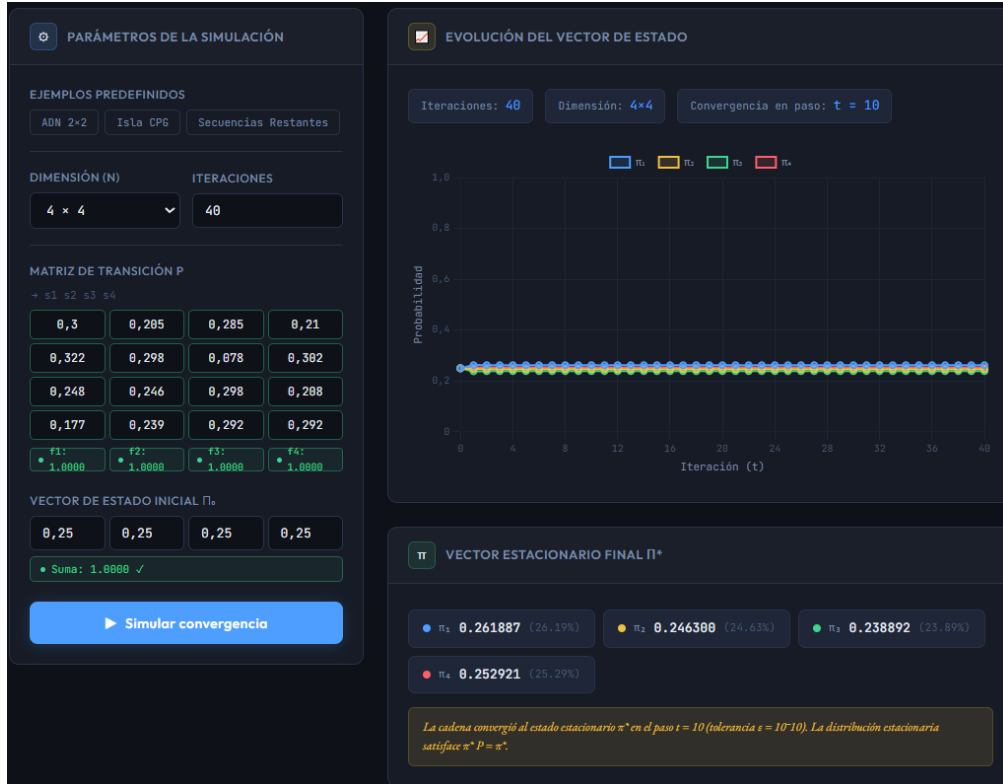


Figura 19: Animación Secuencias Restantes

Como vemos, los resultados son idénticos a pesar de la variación en el dato inicial.

#### 4.2.2. Discriminación de secuencias mediante la razón de verosimilitud logarítmica (aplicación computacional)

Si bien el estudio de la distribución estacionaria nos proporciona una confirmación matemática sobre la composición a largo plazo de estos genomas, y resulta muy interesante la observación teórica de su estabilidad, aún podemos llevar la aplicación del modelo un paso más allá. Como adelantamos en la introducción biológica, el verdadero interés práctico para el diagnóstico clínico y el mapeo genómico es la capacidad de identificar y localizar físicamente estas islas CpG ocultas dentro de una inmensa cadena de ADN sin clasificar.

Para lograr esta discriminación y determinar si un fragmento concreto pertenece al "interruptor" de un gen esencial o simplemente a código genérico, conectamos la teoría de las cadenas de Markov con una métrica de evaluación local sobre ventanas de código genético de tamaño arbitrario (*Log-Odds ratio*).

En una Cadena de Markov clásica, la probabilidad de observar una secuencia entera se calcula mediante el producto encadenado de las probabilidades de transición entre sus estados, como explicábamos en la introducción del apartado 4.2.

Para evaluar un fragmento de ADN específico, denotado como  $X$ , "pasamos" dicha secuencia por dos cadenas de Markov distintas operando en paralelo. Así, comparamos la probabilidad conjunta de que la secuencia haya sido generada por el modelo de Isla CpG (modelo +) frente a la probabilidad de que provenga del modelo de ADN genérico (modelo -).

Definimos entonces la puntuación total de la secuencia,  $S(X)$ , de la siguiente manera:

$$\begin{aligned} S(X) &= \log \frac{P(x \mid \text{model}+)}{P(x \mid \text{model}-)} = \sum_{i=1}^L \log \frac{a_{x_{i-1}x_i}^+}{a_{x_{i-1}x_i}^-} \\ &= \sum_{i=1}^L \beta_{x_{i-1}x_i} \end{aligned} \quad (5)$$

Donde hemos definido un nuevo parámetro  $\beta_{x_{i-1}x_i}$  para simplificar el sumatorio. Este valor  $\beta$  representa el "peso" que aporta cada salto de un nucleótido al siguiente. El uso de logaritmos en base dos permite medir la "evidencia" en unidades llamadas bits y evita problemas de underflow (redondeo a cero) en los ordenadores al sustituir la multiplicación de probabilidades ínfimas por sumas directas.

Así, se obtiene una matriz de puntuación donde los números positivos indican una alta probabilidad de estar ante una isla CpG (como se observa en la transición  $C \rightarrow G$ ), y los negativos indican lo opuesto (Figura 20). Nótese que una unidad entera adicional (+1 bit) en esta tabla se traduce en el doble de confianza estadística a favor del modelo de isla CpG.

En el estudio de referencia [10], se propone un algoritmo para analizar una secuencia genómica real, dándose el ejemplo de una compuesta por 60 nucleótidos del parvovirus canino. Inicialmente, el enfoque consiste en dividir arbitrariamente la secuencia en dos mitades y realizar el análisis probabilístico sobre cada fragmento de forma independiente para intentar determinar cuál

| $\beta$ | A      | C     | G     | T      |
|---------|--------|-------|-------|--------|
| A       | -0.740 | 0.419 | 0.580 | -0.803 |
| C       | -0.913 | 0.302 | 1.812 | -0.685 |
| G       | -0.624 | 0.461 | 0.331 | -0.730 |
| T       | -1.169 | 0.573 | 0.393 | -0.679 |

Figura 20: Tabla Log-Odds

de ellos contiene la isla CpG.

Sin embargo, notamos que este algoritmo presenta dos problemas principales: no permite localizar los límites exactos de la isla y, lo que es peor, se corre el riesgo de enmascarar los resultados. Al hacer un corte estático a ciegas, asumimos que por suerte la isla va a encajar perfectamente en uno de los bloques. Si la isla se encuentra entre ambas mitades, o si es mucho más pequeña que el bloque que estamos evaluando, su puntuación positiva se camuflará al promediarse con la negativa del ADN normal que la rodea. Esto puede llevarnos a una localización muy poco precisa o incluso a pasar la isla por alto.

Para solucionar este problema, proponemos otro algoritmo basándonos en los conceptos explicados en [11]. En lugar de analizar secciones completas de la cadena de golpe, aplicamos una “ventana deslizante” de longitud fija (por ejemplo, de 10 nucleótidos). Este método calcula la puntuación del primer fragmento, avanza una sola letra hacia la derecha, y repite el cálculo hasta el final de la cadena. Esto nos permite evaluar y discriminar dinámicamente los cambios de densidad a lo largo de la secuencia, dibujando exactamente dónde empieza y dónde termina la isla CpG.

A nivel computacional, este avance de la ventana deslizante resulta extremadamente eficiente. Dado que la puntuación de la ventana es una suma lineal de valores  $\beta$ , no es necesario recalcular la suma completa de los  $W$  (en nuestro caso, 10) nucleótidos en cada paso. Cuando la ventana avanza una posición, la nueva puntuación se obtiene de forma inmediata tomando el valor de la ventana anterior, restando la puntuación del dinucleótido que sale por el extremo izquierdo, y sumando la del nuevo dinucleótido que ingresa por el extremo derecho:

$$S_{j+1} = S_j - \beta_{\text{saliente}} + \beta_{\text{entrante}} \quad (6)$$

Esta optimización reduce la complejidad del cálculo por cada paso, haciendo que el algoritmo sea viable incluso cuando se analizan genomas enteros con ventanas de gran tamaño.

Para ilustrar el funcionamiento de este algoritmo de forma rigurosa, vamos a modelar el cálculo matemático utilizando álgebra matricial. A modo de demostración, definiremos una secuencia genómica arbitraria de 60 nucleótidos que presenta una transición clara: comienza con una región genérica, atraviesa una isla CpG densa en su tramo central, y finaliza con otra región genérica.

Cabe destacar que este es un ejemplo a escala reducida con fines puramente didácticos. En un entorno real, las secuencias genómicas abarcan millones de pares de bases y las islas CpG tienen una longitud media que ronda los 1.000 nucleótidos, requiriendo ventanas de evaluación significativamente mayores.

Nuestra secuencia de prueba:

ATATTTACAT AGTAATATAA CGCGCCGGCG CGCGCGCCGT AATTATATAT  
CATATAAATA

Sea  $B$  nuestra matriz empírica de puntuaciones *Log-Odds* (valores  $\beta$  para los humanos, Figura 13) de tamaño  $4 \times 4$ , cuyas filas y columnas representan el orden (A, C, G, T):

Para evaluar una ventana deslizante de tamaño  $W = 10$ , siguiendo el modelo de las cadenas de Markov, tendríamos que calcular los productos de los distintos estados por la matriz de transición. Con la simplificación logarítmica propuesta, bastaría con sumar dichas puntuaciones. Sin embargo, para terminar de optimizar el algoritmo, definimos una Matriz de Frecuencia de Transiciones, denotada como  $C$ . Cada elemento  $c_{st}$  de esta matriz almacena el recuento exacto de cuántas veces ocurre el salto del nucleótido  $s$  al nucleótido  $t$  dentro de la ventana actual. Así, la puntuación total de la ventana se obtiene calculando la traza del producto matricial entre la matriz de frecuencias transpuesta y la matriz de puntuaciones (Expresión 7):

$$S = \text{Tr}(C^T \cdot B) \quad (7)$$

Tomamos el primer fragmento de la secuencia (ATATTTACAT). Evaluamos las 9 transiciones presentes y construimos su matriz de frecuencias  $C_1$ :

Nuestra matriz  $C_1$  queda definida como:

$$C_1 = \begin{pmatrix} 0 & 1 & 0 & 3 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 2 \end{pmatrix} \quad (8)$$

Aplicamos el producto sobre nuestra matriz  $B$  para obtener la puntuación inicial (Expresión 7):

$$\begin{aligned} S_1 &= \text{Tr}(C_1^T \cdot B) \\ &= (1 \times 0,419) + (3 \times -0,803) + (1 \times -0,913) + (2 \times -1,169) + (2 \times -0,679) \\ &= -\mathbf{6,599} \text{ bits} \end{aligned}$$

Este resultado fuertemente negativo indica con alta confianza que este primer fragmento pertenece a ADN no codificante ordinario (no CpG).

Como comentamos previamente, para calcular el resto de ventanas (la siguiente sería TATTTACATA), el algoritmo no necesita reconstruir la matriz  $C$  desde cero en cada avance. Si definimos matrices canónicas  $E_{st}$  (una matriz nula con un único 1 en la posición de la transición), la matriz de frecuencias de la segunda ventana se obtiene mediante una simple actualización lineal (Expresión 9), lo que a su vez actualiza la puntuación total sumando y restando los valores correspondientes de  $B$ .

$$S_{j+1} = S_j - \text{Tr}(E_{\text{saliente}}^T \cdot B) + \text{Tr}(E_{\text{entrante}}^T \cdot B) \quad (9)$$

Tras la ejecución computacional del algoritmo [4] y la posterior representación de los resultados (Figura 21), se observa un cambio drástico en la tendencia estadística de las puntuaciones. Mientras que los fragmentos inicial y final de la secuencia arrojan valores negativos (propios del ADN genérico), en el tramo central se distingue una transición abrupta hacia puntuaciones fuertemente positivas. De este modo, el gráfico permite identificar y delimitar visualmente con gran nitidez la presencia de la isla CpG, comprendida aproximadamente entre las posiciones 15 y 45 de la secuencia.




Figura 21: Gráfica Identificación Isla CpG

## 5. Otras aplicaciones del modelo de Cadenas de Markov

1. **PageRank:** Cada página web que aparece en el navegador tras realizar una búsqueda puede representarse como un estado de una matriz de transición. Es decir, así como en genética estudiábamos la transición de una base nitrogenada a otra, aquí analizamos el salto a través de un enlace (*link*) hacia otra página web. Este modelo asume que, por ejemplo, si una página tiene 4 enlaces salientes, el usuario tiene un 25 % de probabilidad inicial de acceder a cada uno de ellos. Según la popularidad de cada sitio web, esta probabilidad se moldea, entendiendo que es más probable que se acceda a un enlace que es más visitado. Esto genera una matriz estocástica con miles de millones de filas y columnas (una por cada página web existente), manteniendo las mismas características matemáticas que las del modelo clásico de Markov. La irrupción de la IA ha permitido mayor precisión con un funcionamiento más complejo. [12]
2. **Teclados predictivos:** El autocompletado que se da al escribir en algunas aplicaciones móviles se basaba, hasta hace poco, en cadenas de Markov. El funcionamiento consiste en analizar el historial de tus chats anteriores para crear una propia matriz de transición. Por ejemplo, a partir de la palabra «hola», el sistema puede establecer estadísticamente que

hay un 60 % de probabilidad de que la siguiente palabra sea «qué», un 30 % de que sea «amigo» y un 10 % para otras opciones. De este modo, se construye una matriz de transición de miles de filas y columnas (basada en tu vocabulario) que conserva todas las propiedades del modelo de Markov. Al igual que en el ejemplo anterior, la IA ha modificado el comportamiento de estos algoritmos.[13]

3. **Predicción del clima:** Se trata de una forma rudimentaria de hacer predicciones a corto plazo. Si, basándonos en los datos históricos de una ciudad, sabemos que después de un día lluvioso hay un 50 % de probabilidad de que siga lloviendo al día siguiente, un 30 % de que se nuble y un 20 % de que salga el sol, podemos construir una matriz de transición. Así, si hoy está lloviendo, el modelo simplemente aplica dicha matriz para calcular matemáticamente las probabilidades del estado meteorológico de mañana.[14]

## Referencias

- [1] Ernesto Aceituno Romero, Román Aranguren España, Miguel Crespo Orti, Andrés Fernández Cervell. *Hoja de cálculo*. <https://docs.google.com/spreadsheets/d/1TDjFhDcMi2UGUxIVoR5rzYp0vYRq7BtbmNF7wrLOUpI/edit?gid=0#gid=0>
- [2] Ernesto Aceituno Romero, Román Aranguren España, Miguel Crespo Orti, Andrés Fernández Cervell. *Simulación*. [https://andresfercervell.github.io/Markov-Chains/markov\\_chain\\_simulator.html](https://andresfercervell.github.io/Markov-Chains/markov_chain_simulator.html)
- [3] Ernesto Aceituno Romero, Román Aranguren España, Miguel Crespo Orti, Andrés Fernández Cervell. *Algoritmo*. [https://github.com/AndresFerCervell/Markov-Chains/blob/main/markov\\_chains.cpp](https://github.com/AndresFerCervell/Markov-Chains/blob/main/markov_chains.cpp)
- [4] Ernesto Aceituno Romero, Román Aranguren España, Miguel Crespo Orti, Andrés Fernández Cervell. *Identificador de Islas CpG*. [https://github.com/AndresFerCervell/Markov-Chains/blob/main/identificador\\_cpg.cpp](https://github.com/AndresFerCervell/Markov-Chains/blob/main/identificador_cpg.cpp)
- [5] Ortega Ríos, R. (2025). *Modelos Matemáticos*. Departamento de Matemática Aplicada, Universidad de Granada.
- [6] Aránega Jiménez, A. (2003). *Aplicación de técnicas de Biología Molecular en Genética Clínica*. Editorial Universidad de Granada.
- [7] Deaton, A. M., y Bird, A. (2011). CpG islands and the regulation of transcription. *Genes & Development*, 25(10), 1010-1022. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3093116/>
- [8] Wikipedia. (s.f.). *CpG site*. Recuperado el 1 de mayo de 2026, de [https://en.wikipedia.org/wiki/CpG\\_site](https://en.wikipedia.org/wiki/CpG_site)
- [9] Cáceres Granados, M. J. (2026). *Algunos apuntes sobre la asignatura Modelos Matemáticos I*. Universidad de Granada.
- [10] Quishpe, E., Sánchez, M. E., Oleas-De la Carrera, G., y Paz-y-Miño, C. (s.f.). Identificación de islas CpG en el genoma humano a través de las cadenas de Markov: Un modelo matemático basado en probabilidades.
- [11] Durbin, R., Eddy, S., Krogh, A., y Mitchison, G. (1998). Markov chains and hidden Markov models. En *Biological Sequence Analysis: Probabilistic*



*Models of Proteins and Nucleic Acids* (pp. 46-80). Cambridge University Press.

- [12] Brin, S., y Page, L. (1998). The anatomy of a large-scale hypertextual Web search engine. *Computer Networks and ISDN Systems*
- [13] Jurafsky, D., y Martin, J. H. (2023). N-gram Language Models. En *Speech and Language Processing* (3.<sup>a</sup> ed., cap. 3). Stanford University.
- [14] Ross, S. M. (2014). Markov Chains. En *Introduction to Probability Models* (11.<sup>a</sup> ed., cap 4, Markov Chains). Academic Press.
- [15] Genotipia. (2025, 31 julio). El Día del ADN. Un paseo por la historia de la Genética Humana. <https://genotipia.com/historia-adn/>